

MORROWLAB

Personalized Learning Analytics & Adaptive Study Planning

Product Requirements Document / 개발 계획서

Product Thesis

MorrowLab은 공부 시간을 기록하는 앱이 아니라, 사용자의 실제 행동과 학습 결과를 관찰해 “나에게 어떤 공부 조건이 가장 효과적인지” 학습하고 다음 일정을 자동으로 조정하는 개인화 학습 시스템이다.

기간	개발	디자인
약 3-4개월	Full-stack 3명	UI/UX 1명

North Star

“How do I learn best?”에 데이터를 기반으로 답하는 제품

Working name: MorrowLab · Version 0.1 · 2026

제품 정의 & 문제 설정

MVP 범위를 흔들지 않기 위한 기준점

Problem

학생들은 To-do, 캘린더, 타이머로 “무엇을 얼마나 했는지”는 기록할 수 있지만, 어떤 조건에서 실제 학습 효과가 좋아지는지는 알기 어렵다.

집중은 시간대, 과목, 세션 길이, 휴대폰 사용, 앱 전환, 휴식 패턴 등에 영향을 받지만 이 데이터가 분산되어 있다.

일정 추천 앱도 많지만 대부분 사용자의 실제 공부 행동과 학습 결과를 학습해 다음 계획을 바꾸지는 않는다.

Target User

Primary	상황 / Pain Point	MorrowLab 이 제공하는 가치
대학생	과제·시험·프로젝트가 동시에 겹치고, 매일 공부 컨디션이 다름	행동 데이터 기반으로 현실적인 세션과 시간대 추천
시험 준비생	긴 기간 동안 루틴을 유지하고 복습 타이밍을 관리해야 함	장기 패턴 + retention 기반 일정 최적화
자기주도 학습자	타이머 기록은 많지만 무엇이 효과적이었는지 알기 어려움	개인별 패턴과 실행 가능한 인사이트 제공

Product Goals

1	Observe 공부 세션 중 카메라와 컴퓨터 활동에서 설명 가능한 observable event 를 추출한다.
2	Measure 세션 종료 후 self-evaluation 과 짧은 성과 지표를 연결한다.
3	Learn 누적 데이터를 바탕으로 사용자별 학습 패턴과 세션 효과를 모델링한다.
4	Adapt 학습된 패턴으로 다음날/다음 주 공부 일정을 재배치하고 추천한다.
Non-goal “표정만 보고 집중도 87%”처럼 불명확한 감정 추론을 핵심 기능으로 두지 않는다. MorrowLab 은 폰 사용, 자리 비움, 앱 전환처럼 관찰 가능한 행동과 실제 학습 결과를 연결한다.	

핵심 사용자 플로우

매일 반복되는 루프가 곧 데이터 수집 및 개인화 루프

1	Plan	오늘 할 일·과제·deadline 입력 / 캘린더 연동
2	Start	과목·세션 목표 선택 후 “공부 시작”
3	Observe	카메라 행동 이벤트 + 앱/웹 사용 이벤트 로컬 추적
4	Reflect	세션 종료 후 10-20 초 self evaluation + 선택적 mini quiz
5	Analyze	세션 점수, 패턴, distraction, 완료율 업데이트
6	Adapt	내일 할 일의 시간대·순서·세션 길이를 자동 추천

Daily Output

Output	예시
Session Summary	45 분 중 집중 행동 33 분 / 폰 이벤트 3 회 / 자리 비움 1 회
Self Evaluation	집중도 4/5 · 이해도 3/5 · 목표 완료 80%
Insight	오전 수학 세션은 야간보다 완료율과 recall 이 높음
Tomorrow Plan	수학은 오전 10:00, 읽기는 오후 3:00, 복습은 저녁 7:30 추천

공부 점수: MVP에서는 “진단”이 아니라 “요약”

단일 숫자를 절대적 능력 점수처럼 제시하지 않고, 세션 비교용 composite score 로 사용한다.

예: 목표 완료율 + self evaluation + 행동 안정성 + 선택적 quiz/recall 결과를 가중 결합.

사용자에게는 총점뿐 아니라 어떤 요소가 점수에 영향을 줬는지 설명한다.

예시

Today: 78/100 · 목표 완료 90% · 폰 distraction 3 회 · 이해도 4/5 · 지난 7 일 평균 대비 +8

기능 요구사항 & 우선순위

MVP 는 “데이터 루프가 실제로 돈다”에 집중

Priority	Feature	Requirement / Done Definition
P0	Task & Session	할 일 생성, 과목/목표/예상 시간, 세션 시작·종료, 완료 상태
P0	Camera Event Detection	study / phone / away 등 핵심 행동 3-5 개를 로컬에서 분류하고 event timeline 생성
P0	Desktop Activity	앱/웹사이트 사용 시간 및 context switching 이벤트 수집
P0	Reflection	집중도·이해도·목표 완료율 등 10-20 초 내 입력 가능
P0	Dashboard	세션 summary, 일/주 단위 패턴, distraction, 완료율 시각화
P0	Adaptive Plan	누적 데이터 기반으로 다음날 task 순서/시간대/세션 길이 추천
P1	Calendar Sync	Google Calendar 등에서 busy block / deadline import 및 추천 일정 export
P1	Mini Recall	선택적 1-3 문항 recall 기록으로 outcome signal 강화
P1	Personalization	초기 global model → 사용자 데이터가 쌓일수록 개인별 calibration
P2	Cross-device	모바일 task/check-in, 데스크톱 session 연동

MVP 성공 조건

한 사용자가 5 일 이상 “Plan → Observe → Reflect → Adapt” 루프를 반복할 수 있다.

카메라 이벤트가 실제 환경에서 유의미한 정확도로 작동하고, 오류를 수정할 수 있다.

추천 일정이 “왜 이렇게 배치됐는지” 최소 1 개의 근거를 설명할 수 있다.

raw video 없이도 필요한 analytics 가 생성된다.

ML / 데이터 설계

모델 자체보다 “정확도 개선 → 개인화 → 실제 결과 연결”을 프로젝트의 기술 축으로 설정

A. Camera Behavior Recognition

항목	초기안
Class	studying / reading-writing / phone usage / away from desk / other
Baseline	pretrained lightweight vision model + transfer learning
Temporal	단일 frame 결과 smoothing → 필요 시 short clip / temporal model 확장
Evaluation	precision, recall, F1, confusion matrix + user-level test split
개선 루프	오분류 수정 UI → 어려운 사례 수집 → 재학습 / augmentation

B. Study Effectiveness Model

Input Signals	Potential Outcome
시간대, 과목, 세션 길이, break, phone event, app switching, 최근 workload	세션 목표 완료율
동일 + self evaluation history	이해도 / 만족도 예측
동일 + recall 결과가 있는 경우	다음날 recall / retention proxy

초기에는 interpretable baseline (예: linear/tree-based)으로 시작하고, 데이터량이 확보될 때 더 복잡한 모델과 비교한다.
사용자별 데이터가 적은 cold start 단계에서는 global trend + 규칙 기반 추천을 사용한다.

C. Ground Truth 전략

핵심 원칙

카메라가 “집중”을 직접 정의하지 않는다. observable behavior + self evaluation + goal completion + 선택적 recall 을 함께 사용해 학습 효과를 추정한다.

Self evaluation: 집중도 / 이해도 / 난이도 / 만족도

Behavioral: 목표 완료 여부, 세션 중 interruption, 실제 사용 시간

Learning outcome (선택): 세션 직후 mini quiz 또는 24h recall

시스템 아키텍처 & 개인정보

기본 원칙: 영상은 로컬, 서버에는 최소한의 이벤트와 학습 데이터만

High-level Architecture

1	Desktop Client Camera inference · app/site tracking · session timer
2	Local Event Layer phone_usage / away / study + duration / timestamp
3	Backend API auth · tasks · sessions · aggregated events · recommendations
4	ML Services effectiveness prediction · personalization · schedule ranking
5	Web/Mobile UI planner · dashboard · insights · reflection

Privacy-by-Design

원칙	구현 방향
Raw video	기본 저장하지 않음. 가능한 경우 inference 후 즉시 discard
Server data	event type, timestamp, duration, task/session metadata 중심
Transparency	사용자가 현재 어떤 센서/데이터가 수집되는지 항상 확인 가능
Control	카메라/desktop tracking 개별 off, 특정 앱/사이트 제외 가능
Deletion	사용자별 session/event 데이터 삭제 기능
Model training	beta 단계에서는 명시적 동의가 있는 데이터만 학습에 사용

권장 저장 형태

video frame → local inference → {event: "phone_usage", start: 14:31, duration: 121s, confidence: 0.91} → aggregated event 만 저장

일정 재조정 로직

추천이 “AI가 알아서”가 아니라 제약조건과 학습 신호를 함께 사용하도록 설계

Inputs

할 일: deadline, 예상 소요시간, 중요도, 과목/유형, 분할 가능 여부
사용자 availability: 수업, 약속, sleep window, 캘린더 busy block
과거 성능: 시간대별 완료율, distraction rate, self evaluation, recall
최근 상태: 오늘 공부량, 연속 세션 수, 미완료 task

Scheduling Objective

Conceptual Objective

deadline 을 지키면서, 사용자별 예상 학습 효과가 높은 시간대에 적합한 과제를 배치하고 과도한 연속 세션을 피한다.

Constraint / Signal	예시
Hard constraints	수업 11:00-12:15, 과제 마감 23:59, 사용 가능 시간 09:00-22:00
Task fit	문제풀이 45-60 분, reading 30-40 분, review 20 분
Personal pattern	수학은 오전 성과 ↑, reading 은 오후 성과 ↑
Fatigue guard	90 분 이상 연속 high-focus 세션 지양
Explainability	“최근 수학 세션이 오전에 18% 더 잘 완료되어 10 시에 배치”

추천 단계

MVP: 규칙 기반 + 개인 통계 기반 ranking
V1: effectiveness predictor 가 각 task/time-slot 의 expected score 를 예측
V2: optimization 으로 전체 하루/주 단위 schedule 을 동시에 배치

3-4 개월 개발 로드맵

기술 위험이 큰 camera/ML 을 앞당겨 검증하고, 제품 루프는 가능한 빨리 end-to-end 로 연결

기간	제품 / Backend	ML / Data	검증 결과물
Week 1-2	PRD 확정, 디자인 flow, auth/task/session schema	class 정의, 데이터 수집·labeling protocol	클릭 가능한 UX + 기술 spike
Week 3-4	Task/session MVP, desktop client skeleton	baseline camera inference, event smoothing	한 세션의 end-to-end event timeline
Week 5-6	Reflection, dashboard v0	dataset v1, fine-tuning, evaluation pipeline	카메라 F1 baseline + 오류 사례 분석
Week 7-8	desktop app/site tracking, analytics	behavior features + session dataset	행동/평가 데이터가 한 session 에 통합
Week 9-10	adaptive plan v0, calendar interface	effectiveness baseline + personal stats	추천 일정 + 설명(reason) 생성
Week 11-12	UX polishing, onboarding, notifications	personalization / calibration 실험	closed beta 시작
Week 13-14	배포 안정화, privacy controls	모델 개선 + latency 최적화	실사용 데이터 기반 iteration
Week 15-16	final release/demo, docs	최종 evaluation / ablation	발표: 제품 + 모델 + 사용자 실험

권장 역할 분담

Owner	Primary	Secondary
Dev A	Desktop client / camera pipeline	local inference optimization
Dev B	Backend / data model / scheduling	deployment / observability
Dev C	Web app / analytics dashboard	calendar integration / experiments
UI/UX	Research / flow / design system	usability test / onboarding

팀 운영 팁

ML 담당자를 한 명으로 고정하지 말고, data collection / labeling / evaluation 은 전원이 참여. 모델 정확도만큼 데이터 정의와 제품 피드백 루프가 중요하다.

시장조사·사용자 검증·성공 지표

배포 전 “학생이 실제로 매일 켜 이유가 있는가?”를 빠르게 검증

시장조사 프레임

Category	조사 질문
Focus timer / blocker	사용자가 왜 매일 쓰는가? tracking 과 행동 변화 사이의 gap 은 무엇인가?
Calendar / AI planner	일정 추천이 실제 행동 데이터를 얼마나 반영하는가? 추천 수정 UX 는 어떤가?
Time tracking	자동 tracking 의 friction, privacy, battery/CPU 이슈는 무엇인가?
Learning analytics	학생이 이해하기 쉬운 insight 는 무엇이며, 어떤 metric 은 오히려 부담을 주는가?

초기 사용자 조사

학생 10-15 명 인터뷰: 현재 공부 계획 방식, 실패 지점, 카메라 사용 거부감, 원하는 insight 조사
Prototype test: “세션 시작 → tracking → reflection → 내일 추천” 전체 flow 의 friction 측정
Beta: 최소 15-20 명, 1-2 주 사용을 목표로 retention 과 추천 수용률 관찰

Product Metrics

Metric	초기 목표 / 해석
Activation	첫날 task 생성 + 1 개 session 완료 + reflection 까지 완료
Loop Completion	Plan → Observe → Reflect → Adapt 완주율
Weekly Retention	다음 주에도 3 회 이상 session 을 시작하는 사용자 비율
Recommendation Acceptance	추천 시간대를 그대로 쓰거나 소폭 수정해 사용한 비율
Insight Usefulness	“이 인사이트가 실제 계획에 도움이 됐다” self-report
Model Quality	행동 class 별 F1, latency, user correction rate

핵심 리스크 & 의사결정

일찍 검증하지 않으면 후반에 프로젝트 전체를 흔들 수 있는 항목

Risk	영향	Mitigation
카메라 정확도 부족	제품 신뢰 하락	class 수를 줄이고 observable event 중심, correction feedback 제공
카메라 거부감	사용자 이탈	local-only, 기본 저장 없음, 명확한 indicator, camera-off mode
개인 데이터 부족	추천이 generic 함	초기 rule/global baseline + 빠른 personalization 가능한 feature 설계
“공부 점수”의 오해	불필요한 경쟁/불안	설명 가능한 세부 지표 + 비교 기준을 본인 과거 데이터로 제한
CPU/battery 부담	장시간 사용 어려움	sampling, lightweight model, event-based inference, 성능 profile
Calendar integration scope	개발 일정 지연	MVP 는 import/export 최소 범위, deep sync 는 P1
추천이 틀림	신뢰 하락	사용자가 drag/edit 가능, 추천 이유 제공, feedback 반영

Open Questions - Sprint 0 에서 결정

- Desktop client 범위: Windows / macOS 중 하나 우선?
- 카메라 class 를 3 개로 시작할지 5 개로 시작할지?
- desktop activity 를 앱 단위로만 볼지, browser domain 까지 볼지?
- mini quiz 를 MVP 에 넣을지 P1 으로 미룰지?
- 추천 일정이 캘린더에 자동 반영되는지, 승인 후 반영되는지?
- Beta 사용자 데이터를 모델 개선에 사용하는 opt-in UX 를 어떻게 설계할지?

최종 프로젝트 스토리

MorrowLab 의 핵심은 “카메라를 썼다”가 아니라, 실제 사용자 행동을 측정하고 → ML 로 패턴을 학습하고 → 다음 계획을 바꾸고 → 그 변화가 다시 데이터가 되는 closed feedback loop 를 구현하는 것이다.